文本挖掘技术(2012春)

第八章：

关联分析技术

杨建武

北京大学计算机科学技术研究所

Email:yangjw@pku.edu.cn

关联分析

- 关联分析：关联规则挖掘
- 关联规则挖掘的典型案例：购物篮问题
- 在商场中拥有大量的商品（项目），如：牛奶、面包等，客户将所购买的商品放入到自己的购物篮中。

A Example


Borden's

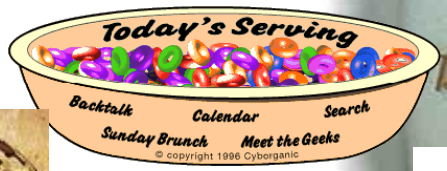
Today's Serving
Backtalk
Calendar
Search
Sunday Brunch
Meet the Geeks
© copyright 1996 Cyborganic


Borden's


50%


Borden's

关联分析

- 通过发现顾客放入购物篮中的不同商品之间的联系，分析顾客的购买习惯
  - 哪些物品经常被顾客购买？
  - 同一次购买中，哪些商品经常会被一起购买？
  - 一般用户的购买过程中是否存在一定的购买时间序列？
- 具体应用：购物篮分析、交叉销售、分类设计等
  - 商品货架设计：更加适合客户的购物路径
    - 两种策略：
      - 商品放近， 增加销量
      - 商品放远， 增加其他商品的销量

关联分析

- 关联规则挖掘：简单的说，就是发现大量数据中项集之间有趣的关联
  - 在交易数据、关系数据或其他信息载体中，查找存在于项目集合或对象集合之间的频繁模式、关联、相关性或因果结构。

关联分析

关联规则挖掘形式化定义：

设$I=\{i_1, i_2, \ldots, i_m\}$是项(item)的集合。

- 若干项的集合，称为项集（Item Sets）.
- 记D为交易(transaction,事务）T的集合，其中，交易T是项的集合，并且$T \subseteq I$ 。
- 对应每一个交易有唯一的标识，如交易号，记作TID 。
- 设X是一个I中项的集合，如果$X \subseteq T$，那么称交易T包含X。

- 寻找：有趣的关联规则(强规则).

关联规则

- 所有形如$X \Rightarrow Y$ 蕴涵式的称为关联规则，这里$X \subset I$，$Y \subset I$，并且$X \cap Y = \Phi$ 。

- 关联规则是有趣的，如果它满足最小支持度阈值与最小置信度阈值，并称之为强规则

关联规则

为了描述关联规则的有用性和确定性

- 关联规则的支持度
  - 如果交易数据库D中s次交易包含A∪B，则称规则A⇒B在事务集D上的支持度为s。
  - Support(A⇒B)=P(A∪B)

- 关联规则的置信度
  - 如果交易数据库D中，包含A的交易中有c(%)的交易同时也包含B，称规则的置信度为c。（条件概率）
  - Confidence(A⇒B)=P(B|A)
    =support({A}∪{B})/support({A})

（注：这里的∪是指在交易中同时出现{A}和{B}）

关联规则

- 查找所有的规则 $A \Rightarrow C$ 具有最小支持度和可信度
  - 支持度, s, 一次交易中包含{A 、 C}的可能性
  - 置信度, c, 包含{A}的交易中也包含{C}的条件概率

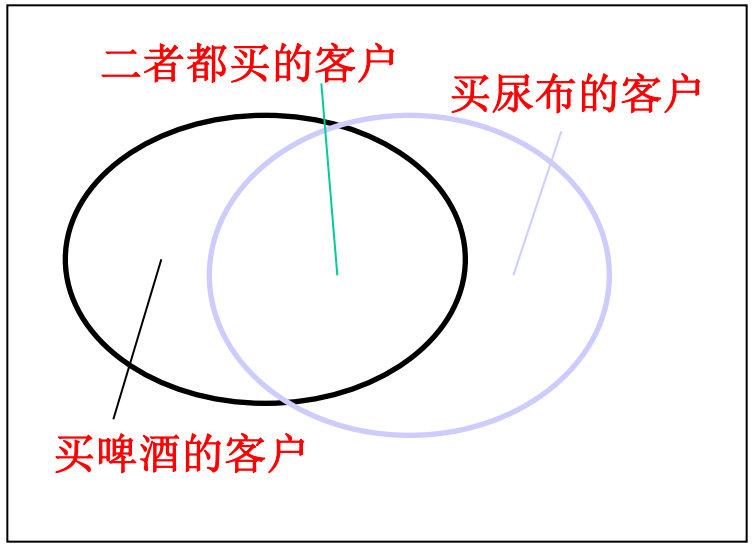

交易ID	购买的商品
10	A,B,C
20	A,C
30	A,D
40	B,E,F

关联规则

Transaction-id	Items bought
10	A, B, C
20	A, C
30	A, D
40	B, E, F

Min. support 50%
Min. confidence 50%

Frequent pattern		Support
{A}	3	75%
{B}	2	50%
{C}	2	50%
{A, C}	2	50%

- rule $A \Rightarrow C$:
  - support = support($\{A\} \cup \{C\}$) = 50%
  - confidence = support($\{A\} \cup \{C\}$)/support($\{A\}$) = 66.7%
- rule C $\Rightarrow$ A : ?

挖掘关联规则方法

频繁项集

- 项集(Itemset): a set of items
  - 例如 acm={a, c, m} , sup=3
- 频繁项集（高频项集）
  - 如果项集满足最小支持度，则称之为频繁项集
  - 如果 min_sup = 3,则 acm 是频繁项集
- 如果频繁项集中包含K个项，则称为频繁K—项集

TID	Items bought
100	f, a, c, d, g, I, m, p
200	a, b, c, f, l, m, o
300	b, f, h, j, o
400	b, c, k, s, p
500	a, f, c, e, l, p, m, n

关联规则挖掘

- 关联规则的挖掘步骤
  - 发现频繁项集
  - 由频繁项集生成满足最小支持度和最小置信度的关联规则
- 发现频繁项集直接的方法
  - 产生所有可能的项集,并测试它们的支持度
  - 100个项 → 2^{100}-1 可能项集

Apriori方法

Agrawal & Srikant 1994, Mannila, et al. 1994

- Apriori性质：一个频繁项集中的任一非空子集也应是频繁项集。
  - 如果一项交易包含{牛奶，面包，汽水}，那么它一定包含{牛奶，面包}
  - {牛奶，面包，汽水}是频繁的 → {牛奶，面包}一定也是频繁的
- 即：任何非频繁项集的超集一定也是非频繁的
  - 非频繁项集的超集可以不用进行测试
  - 许多项之间的组合可以去掉（不满足频繁条件）

Apriori方法

- 寻找最大频繁集
- 逐层搜索的迭代方法。
- 用*k*–项集探求 *(k+1)*–项集。
- 具体地：
  - 首先找出频繁1–项集，该集合记为L_1；
  - 用L_1找出频繁2–项集的集合L_2；
  - 如此继续下去，直到找到最大频繁项集
- 该方法，主要由连接和剪枝两步构成。

Apriori方法

- C_k: Candidate itemset of size k
- L_k : Frequent itemset of size k

- L_1 = {frequent items};
- for (k = 1; L_k !=∅; k++) do
  - C_{k+1} = candidates generated from L_k;
  - for each transaction t in database do
    increment the count of all candidates in C_{k+1} that are contained in t
  - L_{k+1} = candidates in C_{k+1} with min_support
- return $\cup_k L_k$;

Apriori方法

- 产生候选集：
- L_3={*abc, abd, acd, ace, bcd*}
- Self-joining: L_3*L_3
  - *abcd* ← *abc* * *abd*
  - *acde* ← *acd* * *ace*
- Pruning:
  - For each itemset *c* in C_k do
    - For each (*k-1*)-subsets *s* of *c* do if (*s* is not in L_{k-1}) then delete *c* from C_k
  - *acde* is removed because *ade* is not in L_3
- C_4={*abcd*}

Apriori方法

Database TDB

Tid	Items
10	A, C, D
20	B, C, E
30	A, B, C, E
40	B, E

1st scan

C_1

Itemset	sup
{A}	2
{B}	3
{C}	3
{D}	1
{E}	3

L_1

Itemset	sup
{A}	2
{B}	3
{C}	3
{E}	3

C_2

Itemset
{A, B}
{A, C}
{A, E}
{B, C}
{B, E}
{C, E}

2nd scan

C_2

Itemset	sup
{A, B}	1
{A, C}	2
{A, E}	1
{B, C}	2
{B, E}	3
{C, E}	2

L_2

Itemset	sup
{A, C}	2
{B, C}	2
{B, E}	3
{C, E}	2

Self-joining
Pruning

C_3

Itemset
{B, C, E}

3rd scan

L_3

Itemset	sup
{B, C, E}	2

Apriori方法

- Apriori算法的核心:
  - 用频繁的$(k-1)$-项集生成候选的频繁 *k-项集*
  - 用数据库扫描和模式匹配计算候选集的支持度
- *Apriori* 的瓶颈: candidate-generation-and-test
  - 巨大的候选集:
    - 10^4 个频繁1-项集要生成 10^7 个候选 2-项集
    - 要找尺寸为100的频繁模式，如 $\{a_1, a_2, \ldots, a_{100}\}$，你必须先产生$2^{100} \approx 10^{30}$ 个候选集
  - 多次扫描数据库:
    - 如果最长的模式是n的话，则需要 $(n+1)$ 次数据库扫描
- Can we avoid candidate generation?

频繁模式增长算法

- **Mining Frequent Patterns Without Candidate Generation**
- 模式增长的特征
  - 令α为DB的一个频繁集，B为α的条件模式库（一种特殊类型的投影数据库），
  - β 是 B中的一个项，要使α∪β是DB中的频繁集，当且仅当 β 是 B 的频繁项.
- 例：“*abcdef*”是频繁集,当且仅当
  - “*abcde*”是频繁集, 且
  - “*f*”在包含“*abcde*”的事务中是频繁的。
  - （注：支持度按个数算，而不是百分比）

频繁模式增长算法

- Frequent-Pattern Growth（FP-增长）
  - 基于FP-tree（频繁模式树）
  - 将提供频繁集的数据库压缩到一棵FP-tree，但仍保留项集关联信息；
  - 将压缩后的数据分成一组条件模式库（一种特殊类型的投影数据库），每个关联到一个频繁项集；
  - 分别挖掘每个条件模式库

构造FP-tree

TID	Items bought	(ordered) frequent items
100	{f, a, c, d, g, i, m, p}	{f, c, a, m, p}
200	{a, b, c, f, l, m, o}	{f, c, a, b, m}
300	{b, f, h, j, o}	{f, b}
400	{b, c, k, s, p}	{c, b, p}
500	{a, f, c, e, l, p, m, n}	{f, c, a, m, p}

步骤:

1. 扫描数据库一次，得到频繁1-项集
2. 把项按支持度递减排序
3. 再一次扫描数据库，建立FP-tree

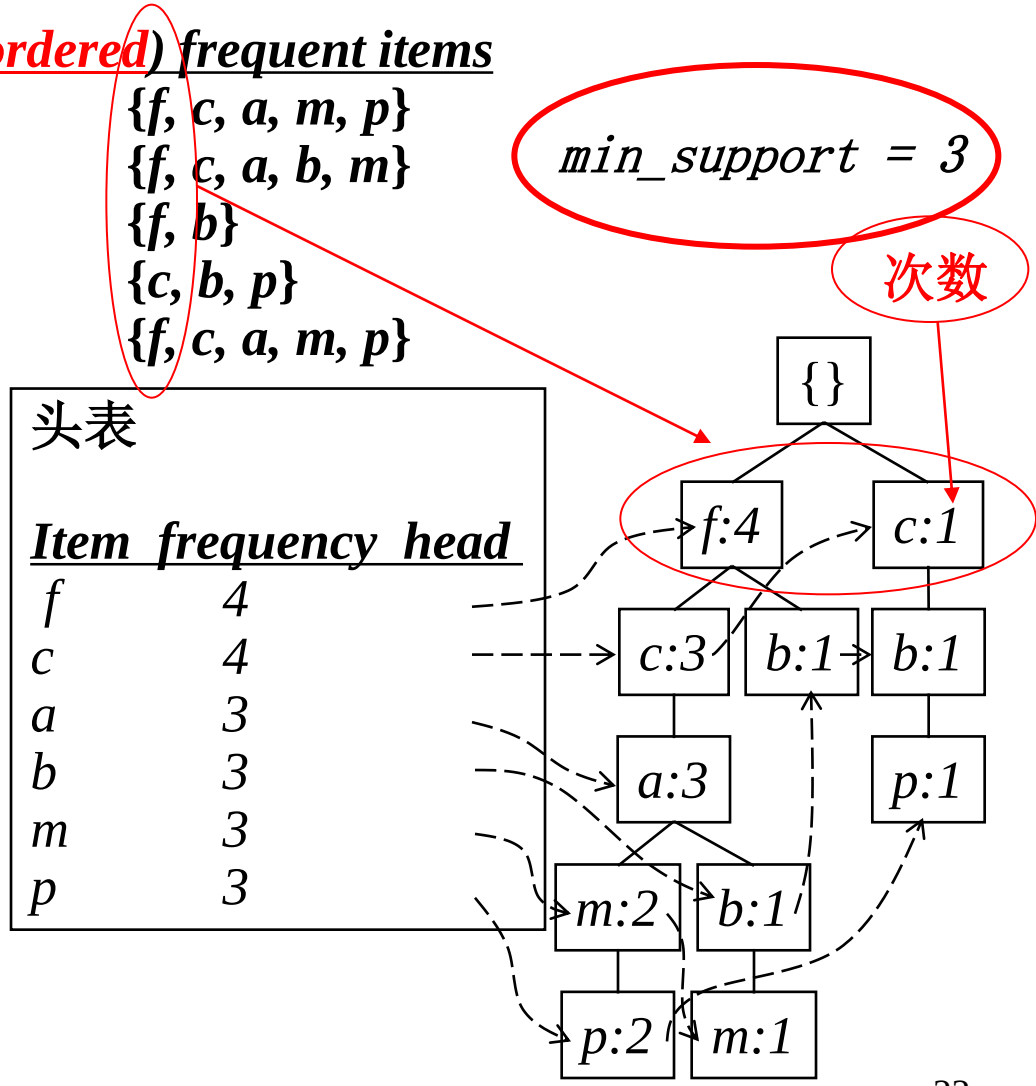

频繁模式增长算法

- 基本思想 (分而治之)
  - 用FP-tree递归增长频繁集
- 方法
  - 对每个项，生成它的条件模式库
  - 用条件模式库构造对应的条件FP-tree
  - 对每个新生成的条件FP-tree，重复这个步骤
  - 直到结果FP-tree为空, 或只含唯一的一个路径 (此路径的每个子路径对应的项集都是频繁集)

步骤1: 从 FP-tree到条件模式库

- 从FP-tree的头表开始
- 按照每个频繁项的连接遍历 FP-tree
- 列出能够到达此项的所有前缀路径，得到条件模式库

条件模式库

item	cond. pattern base
c	f:3
a	fc:3
b	fca:1, f:1, c:1
m	fca:2, fcab:1
p	fcam:2, cb:1

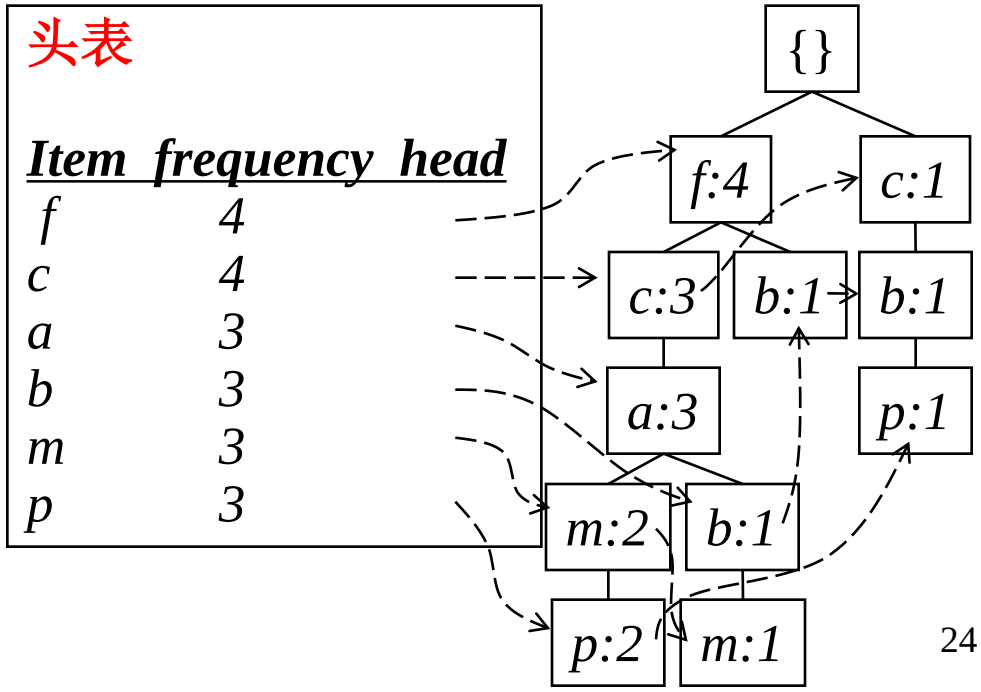

FP-tree支持条件模式库构造

- 节点链接
  - 任何包含a_i, 的可能频繁集，都可以从FP-tree头表中的a_i出发，沿着a_i的节点链接得到
- 前缀路径
  - 要计算路径P 中包含节点a_i的频繁集，只要考察到达a_i的路径前缀即可，且其支持度等于节点a_i的支持度

步骤2: 建立条件 FP-tree

- 对每个条件模式库
  - 计算库中每个项的支持度
  - 用模式库中的频繁项建立该项的条件FP-tree

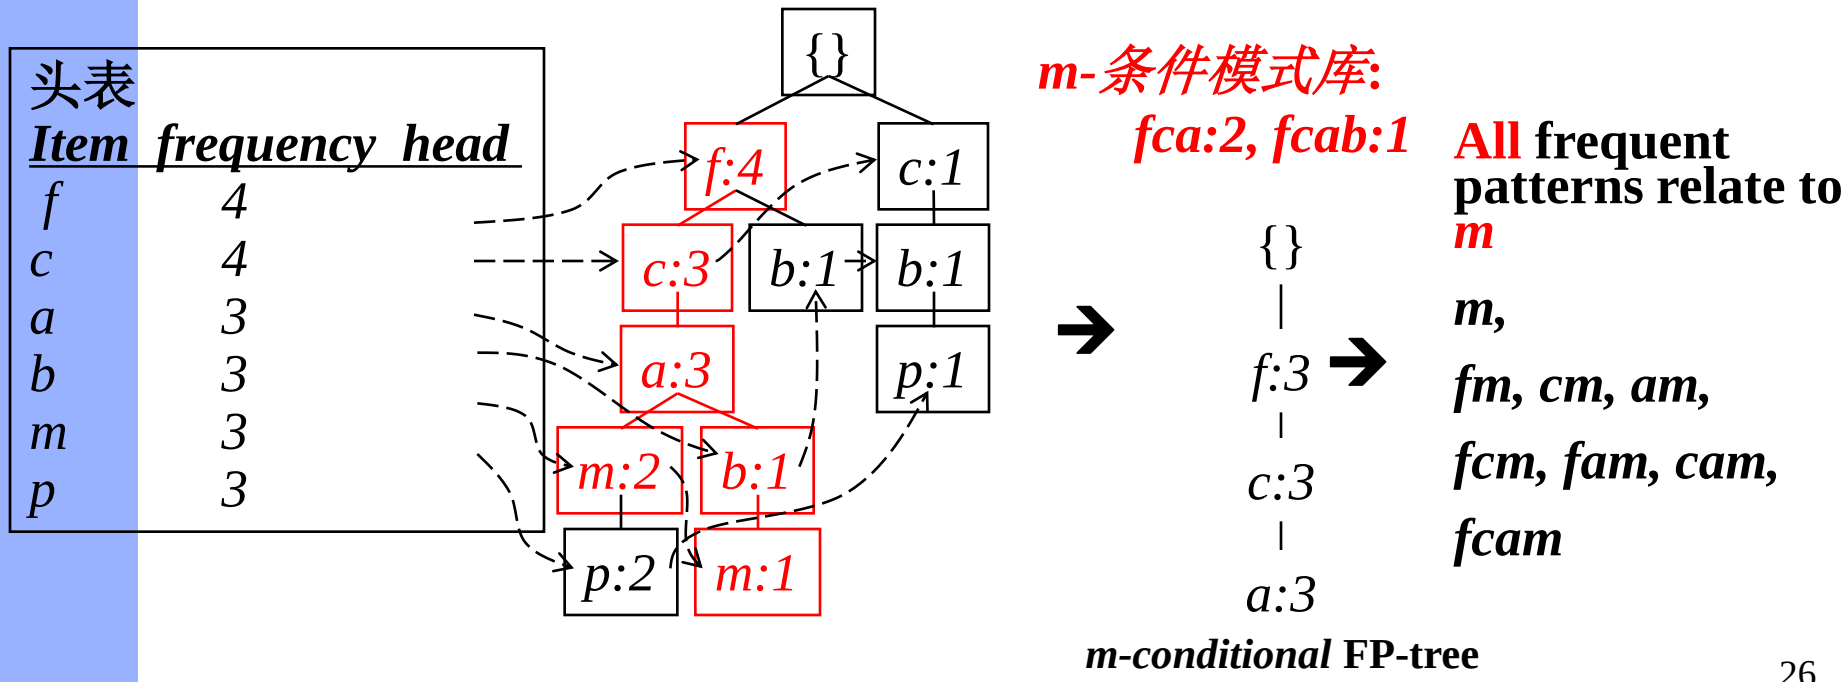

通过建立条件模式库得到频繁集

项	条件模式库	条件FP-tree
p	{(fcam:2), (cb:1)}	{(c:3)}|p
m	{(fca:2), (fcab:1)}	{(f:3, c:3, a:3)}|m
b	{(fca:1), (f:1), (c:1)}	Empty
a	{(fc:3)}	{(f:3, c:3)}|a
c	{(f:3)}	{(f:3)}|c
f	Empty	Empty

第3步: 递归挖掘条件FP-tree

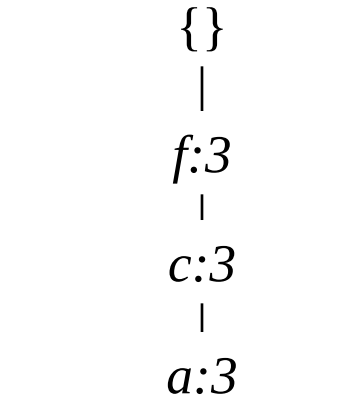

***m*-条件 FP-tree**

"am"的条件模式库: (fc:3)

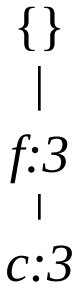

***am*-条件 FP-tree**

"cm"的条件模式库: (f:3)

***cm*-条件 FP-tree**

"cam"条件模式库: (f:3)

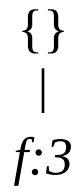

***cam*-条件 FP-tree**

特例: FP-tree 中的唯一前缀路径

- 假定一个 (条件) FP-tree T 有一个共享唯一前缀路径 P
- 挖掘可分解为如下两个步骤
  - 用一个节点代替此前缀路径P
  - 分别计算这两个部分的结果

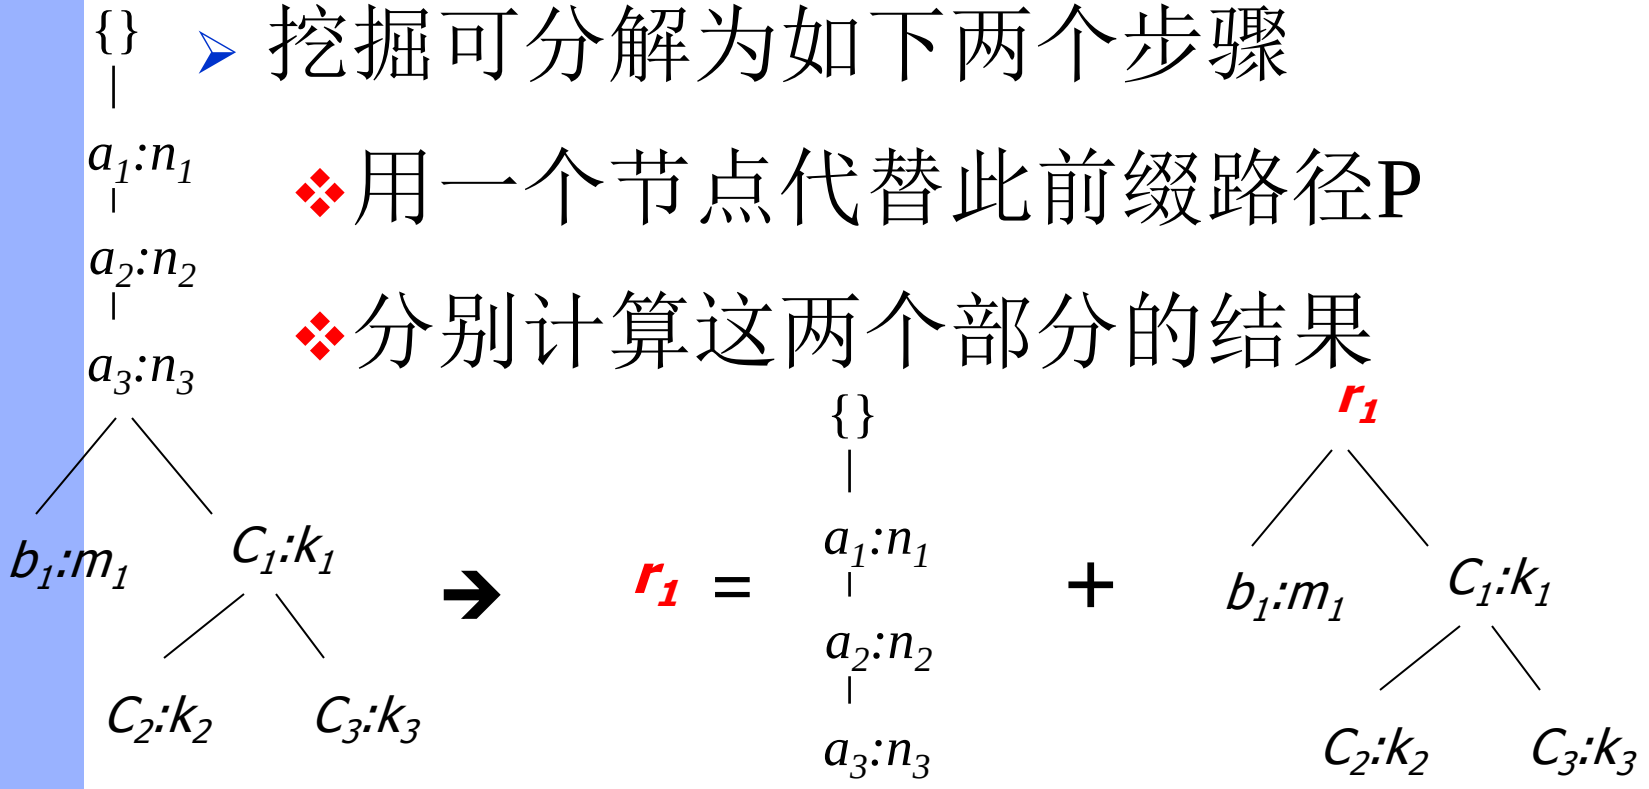

FP-tree 结构的好处

- 完备:
  - 不会打破交易中的任何模式
  - 包含了序列模式挖掘所需的全部信息
- 紧密
  - 去除不相关信息—不包含非频繁项
  - 支持度降序排列: 支持度高的项在FP-tree中共享的机会也高
  - 决不会比原数据库大（如果不计算树节点的额外开销)

性能比较

- 性能研究显示
  - FP-growth 比Apriori快一个数量级。
- 原因
  - 不生成候选集，不用候选测试；
  - 使用紧缩的数据结构；
  - 避免重复数据库扫描；
  - 基本操作是计数和建立 FP-tree 树。

FP-growth vs. Apriori: 相对于支持度的扩展性

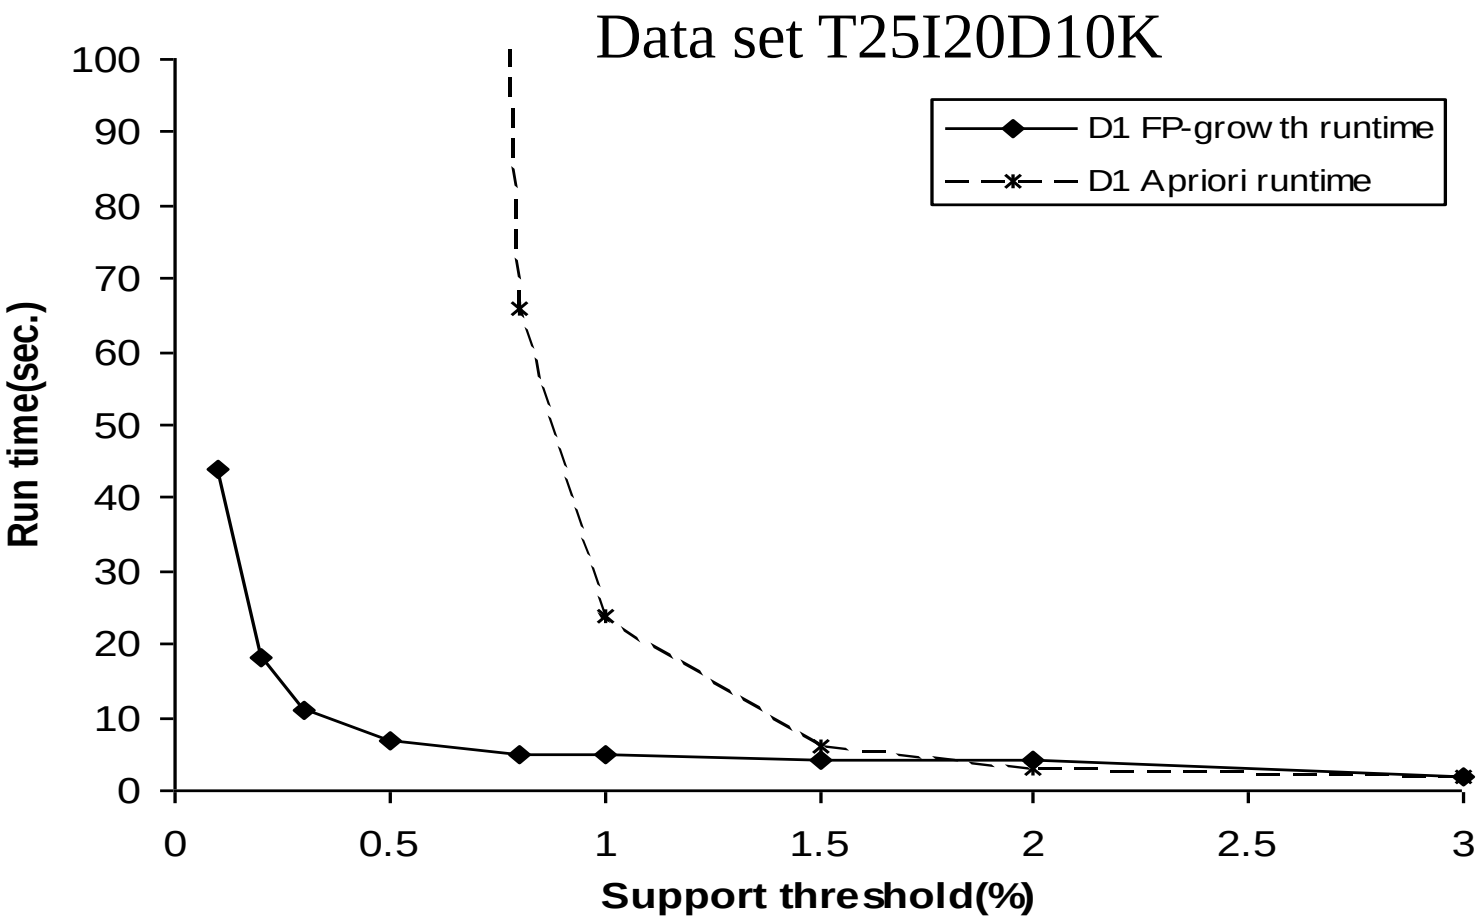

挖掘多层关联规则

- 项通常具有层次
  - 牛奶⇒面包**[20%, 60%].**
  - 酸奶⇒黄面包**[6%, 50%]**

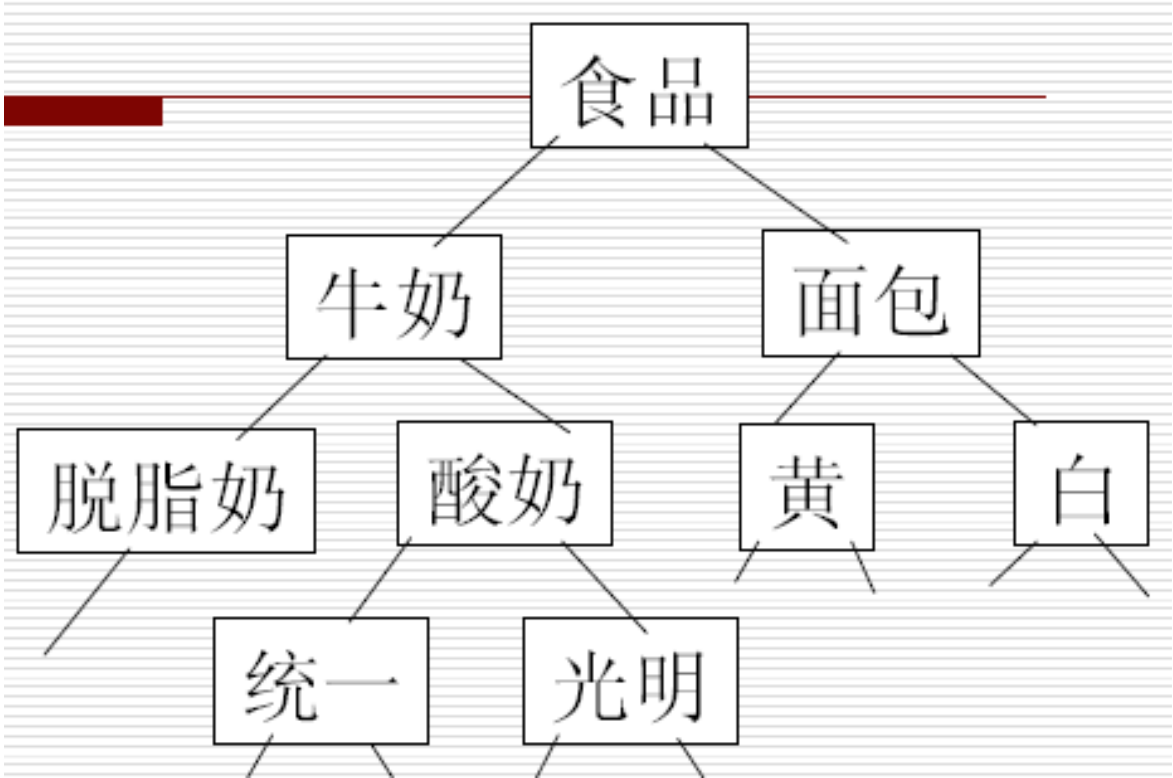

挖掘多层关联规则

- 自上而下，深度优先的方法：
  - 先找高层的“强”规则：

    牛奶⇒面包**[20%, 60%].**
  - 再找他们底层的“弱”规则：

    酸奶⇒黄面包**[6%, 50%].**
- 多层关联规则的变种：

  层次交叉的关联规则：
  - 酸奶⇒北大面包房黄面包

基于关联规则的文本分类

- 文档中的每个单词看作是一个项 (Item)
- 每篇文档看作是一个事务(Transaction)，即：项的集合
- 在不同文档中频繁项集（文档集的单词共同出现，简称“共现”）用于产生分类的规则

小结

- 关联规则概念
- 关联分析的基本方法
- 基于关联规则的文本分类

Any Question?